Temática C: Segmentación y Contaje Automático de Callos Vegetales

Autores:

Antonio Enrique Coll Meseguer – Belén Salar Benito

RESUMEN (Abstract)

El análisis fenotípico de cultivos celulares vegetales mediante métodos tradicionales de contaje manual resulta ineficiente y propenso a la subjetividad del observador. En este trabajo se presenta el desarrollo e implementación de un software de visión artificial basado en la librería OpenCV para la segmentación y cuantificación automática de callos vegetales. A partir de un conjunto de 16 imágenes digitales, se diseñó un flujo de procesamiento que incluye el preprocesamiento mediante filtros de mediana para la reducción de ruido impulsivo y una segmentación en el espacio de color HSV, complementada con una ruta RGB adaptativa para escenas con iluminación irregular.

El punto clave del trabajo fue establecer un umbral mínimo de área de 300 píxeles, lo que permitió discriminar entre tejido vegetal real y artefactos presentes en el medio de cultivo (reflejos o impurezas). El sistema no solo realiza el contaje de individuos, sino también la extracción de parámetros morfológicos como el área proyectada (en píxeles y mm²), el centroide y la circularidad de cada callo. Los resultados obtenidos validan la robustez del algoritmo, logrando un contaje preciso incluso en muestras con condiciones de iluminación desfavorables. HSV ofreció mayor velocidad (~0,04 s/imagen), mientras que RGB fue (~0,11 s/imagen). Este software representa una herramienta objetiva y escalable para el seguimiento de ensayos biológicos in vitro.

Palabras clave: Visión artificial, OpenCV, HSV, callos vegetales, RGB, watershed.

1. INTRODUCCIÓN

El cultivo in vitro de tejidos vegetales es una técnica fundamental en biotecnología, permitiendo la regeneración de plantas, la producción de metabolitos secundarios y el estudio de procesos de diferenciación celular. En este contexto, los callos (masas de células indiferenciadas) son indicadores clave del éxito experimental. Sin embargo, la evaluación del crecimiento y la proliferación de estos tejidos se ha basado tradicionalmente en la inspección visual humana o en el pesaje destructivo de las muestras, métodos que presentan limitaciones en términos de precisión, repetibilidad y tiempo de procesamiento.

Con el avance de la visión artificial, se abre la posibilidad de realizar un seguimiento no invasivo y automatizado. El reto principal radica en la variabilidad intrínseca de las imágenes biológicas: diferencias en la morfología del callo, sombras proyectadas y artefactos lumínicos producidos por los recipientes y el medio de cultivo dificultan una segmentación directa.

En este trabajo se aborda esta problemática mediante el desarrollo de un algoritmo de procesado digital de imágenes utilizando la librería OpenCV. (*opencv-python*, s. f.) El estudio se centra en un conjunto de 16 imágenes digitales, priorizando la robustez del sistema frente a condiciones de iluminación heterogéneas. La metodología propuesta busca no solo el contaje individualizado, sino también la extracción de métricas cuantitativas como el área proyectada y el centroide, facilitando un análisis fenotípico más riguroso y objetivo.

2. MATERIALES Y MÉTODOS

2.1. Dataset y entorno de trabajo

Se trabajó con 16 imágenes digitales en formato PNG (muestras p100 a p133). Debido a las variaciones de contraste y ruido visual en el medio de cultivo, se optó por un procesamiento en lote mediante un script en Python 3, garantizando criterios uniformes para todas las muestras.

2.2. Preprocesado, segmentación y limpieza morfológica

Se aplicó un filtro de mediana para reducir ruido y se segmentó en HSV (tono 10–100) para aislar el tejido vegetal, seguido de apertura morfológica y filtrado por área mínima (300 px). Para imágenes con iluminación irregular, se usó una ruta RGB adaptativa basada en rangos por canal, dominancia del verde y filtro LAB, con ajuste automático de umbrales y fallback a HSV si es necesario. Después, el proceso incluye semillas, watershed, fusión de fragmentos y filtrado final por área y circularidad (Gonzalez & Woods, 2017).

2.3. Extracción de parámetros

Para cada callo validado se calcularon el área (tanto en pixeles y mm^2), el centroide mediante momentos geométricos y la circularidad. Los resultados se guardaron en formatos TXT y CSV para su análisis. Ejemplo de salida: (p100) Callo 1: 4923.0 px (12.308 mm^2) | centroide=(348,93) | circ=0.398

Tabla 1. Parámetros del algoritmo utilizado HSV vs RGB.

Parámetro	Valor	Parámetro	Valor
Modo de color	HSV	Modo de color	RGB adaptativa
Área mínima	300 px	Área mínima	300 px
Rango HSV (bajo)	[10, 30, 30]	Rangos R/G/B	R:20–210; G:80–255; B:10–150
Rango HSV (alto)	[100, 255, 255]	Dominancia verde	G>R+10 y G>B+10
Filtro de mediana	5×5	Proporción verde	G/(R+G+B) ≥ 0.36
Kernel apertura	3×3	Filtro LAB (canal a)	a ≤ 128
DISK_ERODE	7	Ajuste automático	Sí (relaja/endurece umbrales)
PEAK_FRAC	0.65	Filtro morfológico	Apertura 3×3
BG_DIL_ITERS	2	DISK_ERODE	7
MERGE_DIST	25 px	PEAK_FRAC_COMP	0.55
CIRC_MIN	0.12	MIN_PEAK_DIST	9
Semillas por componente	No	BG_DIL_ITERS	2
Escala px/mm	Global o Hough	MERGE_DIST	25 px
Factor de conversión	1px = 0.0025mm^2	CIRC_MIN	0.12
		Escala px/mm	Global o Hough

2.4. Sistema de adquisición propuesto

Para que el método sea reproducible, hemos definido un sistema basado en un sensor CMOS de 12 MP. Esta resolución es clave, ya que permite cubrir un Field of View (FOV) de 90 mm manteniendo una densidad de píxeles que cumpla el criterio de Nyquist para detalles de hasta

0,5 mm. La captura se realizará de forma cenital a una Distancia de Trabajo (WD) de entre 25 y 30 cm, utilizando una óptica de montura C (preferiblemente de 35 mm) configurada para obtener una buena profundidad de campo. En cuanto a la iluminación, se optará por un anillo LED sobre un fondo mate para controlar los reflejos especulares. Por último, la calibración se ha automatizado mediante la Transformada de Hough, que detecta el borde de la placa y vincula su diámetro con los 90 mm reales para establecer el factor de escala. El factor de conversión a mm² se obtiene elevando al cuadrado la relación entre el diámetro real de la placa (90 mm) y su diámetro en píxeles detectado por la Transformada de Hough.

3. RESULTADOS Y DISCUSIÓN

El algoritmo procesó las 16 imágenes en pocos segundos, generando un reporte detallado.

En la comparativa entre HSV Y RGB, ambos modelos detectaron 112 callos. Sin embargo, HSV demostró ser más eficiente con un tiempo total de 1,8 s (~0,04 s/imagen), mientras que el modo RGB adaptativo requirió 2,7 s (~0,11 s/imagen); esto supone que el procesado en RGB es un 50% más lento que HSV.

3.1. Precisión del contaje

El sistema identificó correctamente los callos en la mayoría de las placas. Presenta limitaciones cuando los callos están muy próximos, ya que el algoritmo puede fusionarlos y contabilizarlos como uno solo. Además, la segmentación depende de umbrales fijos en HSV, lo que afecta la precisión ante variaciones extremas de iluminación o color. Una mejora futura sería implementar ajuste dinámico de umbrales y normalización del color para aumentar la robustez.

3.2. Parámetros morfológicos

El software permitió cuantificar la biomasa proyectada, con áreas que oscilan entre 327 px (callos jóvenes) y 16.850 px (masas desarrolladas).

3.3. Validación visual

Las imágenes procesadas muestran contornos verdes y centroides numerados, confirmando que el algoritmo no confunde sombras ni bordes del recipiente. La apertura morfológica eliminó artefactos en muestras como p120–p123.

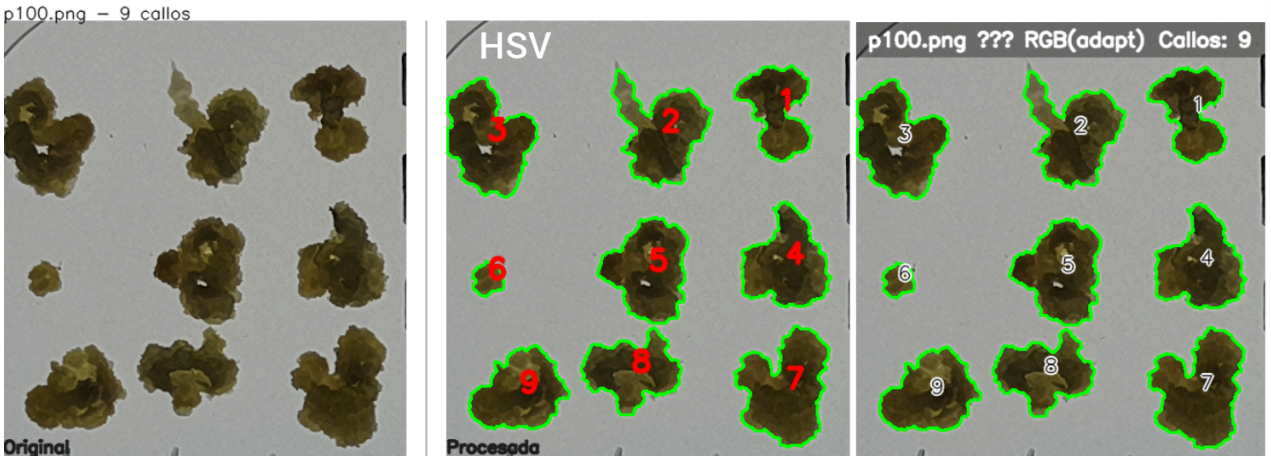

Figura 1. Comparativa entre imagen original y procesada tanto HSV como RGB (p100).

A la izquierda, la imagen original; a la derecha, la imagen segmentada con contornos verdes y numeración en los centroides. El algoritmo detectó 9 callos en esta muestra.

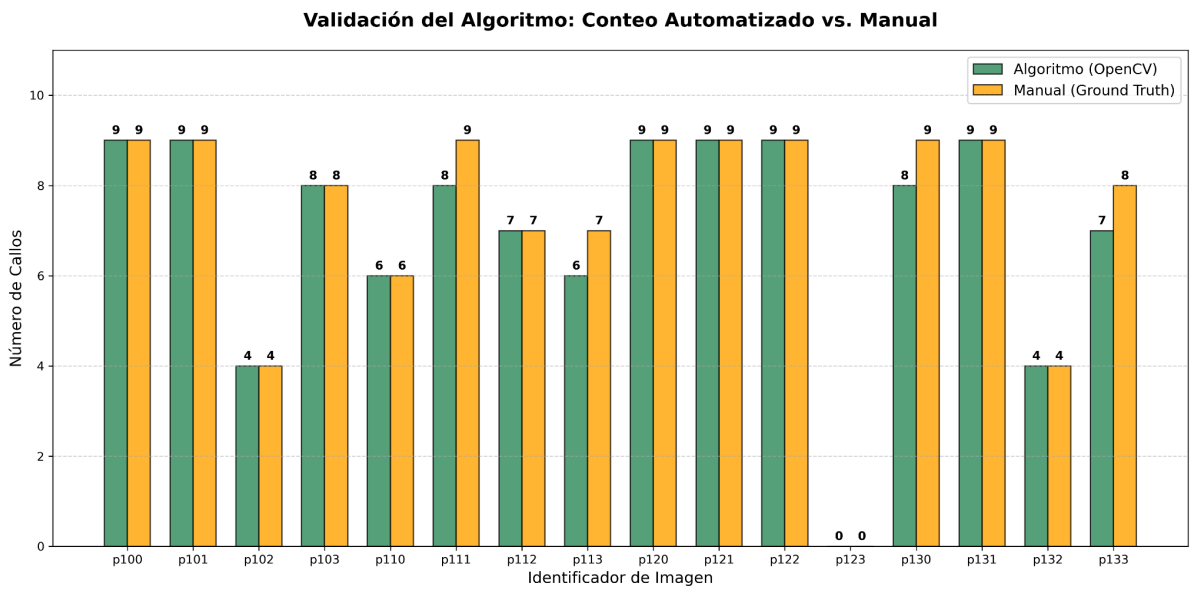

Figura 2. Número de callos detectados por imagen.

El algoritmo procesó 16 imágenes, detectando 112 callos frente a los 115 contabilizados manualmente (Ground Truth), lo que supone una precisión global del 97,4%.

El rango osciló entre 0 y 9 callos por placa, con una media de 7. Las imágenes más densas fueron p100, p101, p120, p121, p122 y p131 (9 callos), mientras que p123 no presentó señal.

Las discrepancias se concentraron en p111, p113, p130 y p133, donde la proximidad de los callos provocó su fusión.

4. CONCLUSIONES

El algoritmo desarrollado cumple con los objetivos de automatización y objetividad planteados. El uso combinado de HSV y RGB adaptativa, junto con watershed y filtrado por área mínima (300 px), resultó determinante para la precisión del sistema. El método procesó 16 imágenes en segundos, detectando 112 callos, lo que demuestra que la visión artificial tradicional es una alternativa viable, rápida y de bajo coste para la monitorización de biomasa vegetal in vitro, facilitando análisis fenotípicos más precisos y escalables.

Como limitación principal, el sistema tiende a fusionar callos próximos y depende de parámetros fijos. En trabajos futuros se plantea incorporar ajuste automático de umbrales y normalización de color para mejorar los resultados ante cambios lumínicos.

5. REFERENCIAS

Gonzalez, R. C., & Woods, R. E. (2017). *Digital image processing* (Fourth edition, global edition). Pearson.

opencv-python: Wrapper package for OpenCV python bindings. (Versión 4.12.0.88). (s. f.). [C++, Python; MacOS, Microsoft :: Windows, POSIX, Unix]. Recuperado 29 de diciembre de 2025, de https://pypi.org/project/opencv-python/